



PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS
Instituto de Ciências Exatas e Informática

Resenha do artigo “*Model Context Protocol (MCP):
Landscape, Security Threats, and Future Research Directions*”

Aluno: Bernardo Carvalho Denucci Mercado

Data: 22/04/2026

Professor: João Paulo Aramuni

Matéria: Projeto de Software

Model Context Protocol (MCP): Landscape, Security Threats, and Future Research Directions

O artigo apresenta uma análise abrangente sobre o Model Context Protocol (MCP), destacando seu papel emergente como um padrão para comunicação entre modelos de inteligência artificial, agentes autônomos e serviços externos. Os autores contextualizam o surgimento do MCP dentro do avanço recente de sistemas baseados em agentes, nos quais modelos de IA não atuam mais de forma isolada, mas sim integrados a ferramentas, APIs e outros agentes, formando ecossistemas complexos e dinâmicos.

Inicialmente, o artigo descreve o MCP como uma solução para a fragmentação existente nas integrações entre sistemas de IA. Ao propor uma comunicação padronizada e bidirecional, o protocolo permite que agentes descubram serviços, compartilhem contexto e executem tarefas de forma mais flexível e escalável. Essa padronização reduz a necessidade de integrações específicas e facilita o desenvolvimento de aplicações mais modulares, nas quais diferentes componentes podem interagir de maneira mais eficiente.

Entretanto, o foco principal do trabalho está na análise dos riscos de segurança introduzidos por esse novo paradigma. Os autores argumentam que, ao ampliar a capacidade de interação entre agentes e sistemas externos, o MCP também expande significativamente a superfície de ataque. Nesse contexto, surge o conceito de uma “cadeia de suprimento de agentes”, na qual não apenas o código, mas também prompts, ferramentas, plugins e serviços externos podem se tornar vetores de ataque.

O artigo identifica e classifica diversas ameaças relevantes. Entre elas, destacam-se a execução de ações maliciosas por agentes com acesso a recursos sensíveis, o vazamento de informações confidenciais por meio de manipulação de contexto e os chamados ataques indiretos, que exploram instruções e dados aparentemente legítimos para induzir comportamentos indesejados. Além disso, a dependência de componentes externos aumenta o risco de comprometimento em cadeia, semelhante a ataques já observados em ecossistemas de software tradicionais.

Como contribuição, os autores organizam essas vulnerabilidades em uma estrutura conceitual clara, propondo uma taxonomia de ameaças que auxilia na compreensão dos riscos associados ao MCP. Também são discutidas lacunas nas abordagens atuais de segurança, evidenciando que os mecanismos tradicionais não são suficientes para lidar com sistemas baseados em agentes e contextos dinâmicos.

Por fim, o artigo conclui que, embora o MCP represente um avanço significativo na interoperabilidade de sistemas de IA, sua adoção deve ser acompanhada por pesquisas mais aprofundadas em segurança. São apontadas como direções futuras o desenvolvimento de mecanismos de validação de confiança, monitoramento de comportamento de agentes e estratégias para mitigação de ataques baseados em contexto.

Dessa forma, o trabalho não apenas apresenta o potencial do MCP como tecnologia, mas também alerta para os desafios críticos que precisam ser enfrentados para garantir sua aplicação segura em ambientes reais.

